

作业 2

丁平尖

2026 年 5 月 18 日

1 注意事项

1. 编程题需要打印相应的输出；
2. 将 ipynb 文件提交至 github 上，命名为：HW02-学号-姓名.ipynb

2 多层感知机

2.1 理论计算题

1. 非线性激活函数的重要性：假设一个具有单隐藏层的多层感知机，输入为 $\mathbf{x}$ ，隐藏层没有激活函数（即线性激活），表达为 $\mathbf{h} = \mathbf{W}_1\mathbf{x} + \mathbf{b}_1$ ，输出层为 $\mathbf{o} = \mathbf{W}_2\mathbf{h} + \mathbf{b}_2$ 。请通过代数推导证明，该网络等价于一个单层神经网络，并写出等价后的权重矩阵 $\mathbf{W}'$ 和偏置向量 $\mathbf{b}'$ 。
2. 激活函数性质分析：写出 Sigmoid(x) 和 tanh(x) 的数学表达式，并推导它们的导数 Sigmoid'(x) 和 tanh'(x) 与其函数自身的关系。

2.2 编程题

不使用深度学习框架的高级 API(仅使用 Tensor 基础算子如 torch.matmul 等)，纯 NumPy 或 PyTorch 从零实现一个多分类（使用 Fashion-MNIST 数据集）的单隐藏层 MLP。

实现要求：

1. 手动初始化隐藏层参数 $\mathbf{W}_1, \mathbf{b}_1$ 和输出层参数 $\mathbf{W}_2, \mathbf{b}_2$ （提示：使用正态分布随机初始化）。

2. 实现 ReLU 激活函数的前向传播: $\max(0, x)$ 。
3. 实现带有 Softmax 的交叉熵损失函数。
4. 编写训练循环, 通过小批量随机梯度下降 (Mini-batch SGD) 手动更新参数。

3 模型选择, 权重衰减和丢弃法

3.1 理论计算题

1. 过拟合与欠拟合: 简述训练误差 (Training Error) 与泛化误差 (Generalization Error) 的区别。当一个模型的训练误差极低, 但泛化误差很高时, 模型处于什么状态? 应该如何通过控制模型复杂度来缓解这一现象?
2. K 折交叉验证: 阐述 K 折交叉验证 (K-fold Cross-Validation) 的具体实施算法步骤。

3.2 编程题

在你实现的 MLP 上, 加入 L_2 正则化和 Dropout 机制。

实现要求:

1. 权重衰减: 在你的自定义 SGD 优化器中, 加入权重衰减。即在计算梯度更新时, 让旧权重首先乘以 $(1 - \eta\lambda)$ 。
2. Dropout 从零实现: 编写一个 `dropout_layer(X, dropout)` 函数。根据传入的概率, 利用随机掩码 (Mask) 将输入张量某些元素置 0, 并进行缩放。注意: 通过一个布尔变量 (如 `is_training`) 来控制测试时不触发 Dropout。
3. 对比实验: 设计高维多项式拟合或使用极少样本训练一个复杂的 MLP, 绘制并对比: 1) 无正则化、2) 有权重衰减、3) 有 Dropout 三种情况下的训练和验证误差曲线 (Loss Curve)。

4 数值稳定性和激活函数

4.1 理论计算题

梯度消失与梯度爆炸：考虑一个 d 层的深层神经网络，其梯度计算包含诸如多层矩阵连乘项 $\prod_{i=t}^{d-1} \frac{\partial \mathbf{h}^{i+1}}{\partial \mathbf{h}^i}$ 。

1. 请从矩阵乘法 and 激活函数导数的角度，量化分析什么情况下会导致梯度爆炸，什么情况下会导致梯度消失。
2. 为什么改用 ReLU 激活函数可以很大程度上缓解梯度消失问题？

4.2 编程题

模拟数值不稳定现象，并验证不同初始化策略对深层网络的影响。
实现要求：

1. 构建深层网络：使用 PyTorch 的高级 API (`nn.Sequential`) 构建一个 20 层的深层全连接网络，隐藏层宽度设为 256。
2. 模拟梯度消失/爆炸：全部激活函数采用 Sigmoid，权重采用普通高斯分布初始化（如 `nn.init.normal_(m.weight, mean=0, std=1)`），输入随机数据，观察并打印前几层和后几层的梯度范数（Gradient Norm），验证梯度消失。
3. 激活函数采用 ReLU，权重采用较大的初值（如 `std=10`），观察是否发生 NaN（梯度爆炸或数值溢出）。
4. 修复与验证：使用 Xavier 初始化（`nn.init.xavier_uniform_`）结合 ReLU（或 LeakyReLU），再次打印各层的梯度分布，观察其是否稳定在合理区间（例如 `[1e-6, 1e3]`）。

5 泛化表现，协变量偏移和对抗性数据

5.1 理论计算题

请结合实际生活中的例子（如医疗、语音识别或电商），详细阐述以下两种环境非平稳性偏移的区别与联系：

1. 协变量偏移 (Covariate Shift): 表现为 $p(\mathbf{x}) \neq q(\mathbf{x})$ 但 $p(y|\mathbf{x}) = q(y|\mathbf{x})$ 。
2. 标签偏移 (Label Shift): 表现为 $p(y) \neq q(y)$ 但 $p(\mathbf{x}|y) = q(\mathbf{x}|y)$ 。

5.2 编程题

动手模拟一个协变量偏移环境, 并使用权重修正改善测试集上的预测性能。

实现要求:

1. 人工数据集构造: 训练集 P : 从正态分布 $\mathcal{N}(-1, 1)$ 中采样 1000 个特征 x , 标签 $y = 2x + \epsilon$ (ϵ 为小噪声)。
2. 测试集 Q : 从正态分布 $\mathcal{N}(2, 1)$ 中采样 500 个特征 x (此时发生了明显的协变量偏移)。
3. 基线模型: 用一个简单的线性回归模型直接在训练集 P 上训练, 并在测试集 Q 上评估, 记录均方误差 (MSE)。
4. 偏移校正实现: 编写一个逻辑回归分类器, 将训练集 P 的样本标记为类别 0, 测试集 Q 的样本标记为类别 1。
 - (a) 将两组数据混合训练分类器, 从而预测出每个样本属于测试集的概率 $P(\text{test}|x)$ 。
 - (b) 根据公式计算每个训练样本的权重 $w_i \propto \frac{P(\text{test}|x_i)}{P(\text{train}|x_i)}$ 。
5. 加权模型训练: 使用这些权重重新训练线性回归模型 (加权最小二乘法), 并再次在测试集 Q 上评估。对比校正前后的测试 MSE, 验证校正效果。