

作业 3

丁平尖

2026 年 6 月 2 日

1 注意事项

1. 编程题需要打印相应的输出；
2. 将 ipynb 文件提交至 github 上，命名为：HW03-学号-姓名.ipynb

2 卷积和池化层

2.1 理论计算题

输入一张大小为 $3 \times 32 \times 32$ (通道数 $\times$ 高 $\times$ 宽) 的彩色图像。通过一个卷积层，该层包含 16 个卷积核，每个卷积核的大小为 $3 \times 5 \times 5$ 。设定填充 (Padding) 为 2，步幅 (Stride) 为 2。

1. 请计算该卷积层输出的特征图 (Feature Map) 的尺寸 (通道数 $\times$ 高 $\times$ 宽)。
2. 计算这个卷积操作中，单个输出通道的一个像素值，需要对输入进行多少次点乘 (乘法) 操作？

2.2 编程题

不使用深度学习框架的底层 Pooling API (如 ‘torch.nn.MaxPool2d’), 仅使用 Python 和 NumPy (或 PyTorch 基础张量操作), 手动实现一个支持步幅 (stride) 和填充 (padding) 的二维最大池化 (Max Pooling) 前向传播函数。

3 LeNet, AlexNet, VGG 和 NiN

3.1 理论计算题

在 VGG 网络中，作者频繁使用多个 3×3 卷积核级联来代替较大的卷积核（如 5×5 或 7×7 ）。假设输入和输出的特征图通道数均为 C 。

1. 计算一个 5×5 卷积层（不带偏置）的参数数量。
2. 计算两个串联的 3×3 卷积层（不带偏置，两层通道数都为 C ）的总参数数量。

3.2 编程题

NiN 网络的核心创新是引入了“ 1×1 卷积”组成的 NiN 块来代替传统的全连接层，以减少参数量。请使用 PyTorch（‘torch.nn.Sequential’）定义一个标准的 NiN 块（NiN Block）。

要求：NiN 块接收输入通道数 ‘in_channels’ 和输出通道数 ‘out_channels’，它由一个普通的卷积层（指定窗口大小 ‘kernel_size’，步幅 ‘stride’，填充 ‘padding’）以及两个随后的 1×1 卷积层级联组成。每层卷积后都需要紧跟一个 ReLU 激活层。

4 Inception, 批量归一化和残差网络

4.1 理论计算题

在一个小批量（Mini-batch）训练中，某一个通道内某一特定空间位置的特征值在 4 个样本上的输出分别为： $x_1 = 2, x_2 = 4, x_3 = 6, x_4 = 8$ 。假设当前批量归一化层学到的缩放参数 $\gamma = 2$ ，平移参数 $\beta = 1$ ，常数 $\epsilon = 0$ 。

请计算这 4 个样本经由该 Batch Normalization 层转化后的最终输出值 y_1, y_2, y_3, y_4 。

4.2 编程题

残差网络（ResNet）通过引入跨层连接（残差连接）解决了深层网络的梯度消失问题。请用 PyTorch 自定义一个残差块类 ‘Residual’。

要求：该块包含两个具有相同输出通道数的 3×3 卷积层，每个卷积层后跟一个批量归一化层。如果 `'use_1x1conv=True'`，则需要对输入应用一个 1×1 的卷积层来调整输入的通道数和形状，以便它能和第二层卷积的输出进行按元素相加 ($f(x) + x$)。

5 图像增广，微调和样式迁移

5.1 理论计算题

在微调 (Fine-tuning) 任务中，我们通常会在一个大型源数据集（如 ImageNet）上预训练好的网络模型基础上，去适应一个新的目标数据集。请回答以下关于微调理论的问题：

1. 为什么我们通常对除了最终输出层之外的“底层特征提取层”设置较小的学习率（甚至将其参数固定/冻结），而对新初始化的“顶层输出层”设置较大的学习率？
2. 如果目标数据集非常小，且与源数据集非常相似，我们应该采取什么样的微调策略以防止过拟合？

5.2 编程题

图像增广能有效增强模型的泛化能力。请利用 `'torchvision.transforms'` 模块创建一个组合图像增广管道 (Pipeline)。

1. 随机对图像进行裁剪，使其面积比例在 0.08 到 1.0 之间，并将裁剪后的图像缩放到 224×224 像素。
2. 拥有 50% 的概率对图像进行水平翻转。
3. 随机改变图像的亮度 (Brightness)、对比度 (Contrast) 和饱和度 (Saturation)，变化范围设为 0.5。
4. 最终将图像转换为 PyTorch 张量 (Tensor)。

6 目标检测，计算机视觉训练技巧

6.1 理论计算题

在目标检测中，交并比 (IoU) 用于衡量预测边界框与真实边界框的重合程度。已知图像中两个边界框 (以 ‘[左上角 x, 左上角 y, 右下角 x, 右下角 y]’ 格式表示):

1. 真实框 (Ground Truth) $A = [10, 10, 50, 50]$
2. 预测框 (Prediction Box) $B = [30, 30, 70, 70]$

请计算边界框 A 和边界框 B 之间的 IoU 准确值。

6.2 编程题

在计算机视觉训练技巧中，标签平滑 (Label Smoothing) 通过防止模型过于自信地预测某些类别来提高泛化性。标准交叉熵使用独热编码 (One-hot)，若设置平滑因子 $\epsilon = 0.1$ ，则对于 K 分类问题，真实标签对应的目标概率从 1 变为 $1 - \epsilon$ ，其余错误类别的概率从 0 变为 $\frac{\epsilon}{K-1}$ 。

请实现一个计算标签平滑后交叉熵损失的函数。